

当随机划分误导我们：天然产物虚拟筛选的外推崩塌量化与不确定性校准的局限——兼论保肝中药的置信度加权排序

王启龙，〔作者名单待补〕，姜希伟*

沈阳药科大学医疗器械学院，辽宁 沈阳

*通讯作者：姜希伟（投稿时补全邮箱）

关键词：不确定性量化；骨架划分；共形预测；天然产物；图神经网络；虚拟筛选；法尼醇X受体；适用域

读者指引：一页看懂本文

本文回答一个朴素的问题：机器学习模型在“考试出现没见过的题型”时还靠谱吗？它的“自信程度”还能信吗？

用考试打比方贯穿全文：

概念	考试类比
随机划分	训练和考题来自同一题库，做过的原题换个数字再考
骨架划分	考的全是新题型，只考你有没有真学会
点预测（ pIC_{50} ）	你给出的答案
σ （预测不确定度）	你對自己答案的“心虚程度”
95%覆盖率	“真实答案落在我的答案±误差范围内”这句话，100次里应有95次说对
共形校准（conformal）	用一份旧考卷的答题误差，反过来划定新考试的容错分数线
杠杆/适用域	你复习过的“地图范围”，地图外的点本该标红警告

四句话总结结论：

- 换成新题型（骨架划分），模型成绩从优秀（ $R^2=0.79$ ）崩到不及格（ $R^2=-0.61$ ），三种模型全部崩——说明这是题目的问题（数据分布），不是学生的问题（模型架构）。 R^2 为负可以通俗理解为：还不如直接猜全班平均分。
- 模型的“心虚程度”在熟悉领域是准的（心虚的确实错得多，相关+0.585），到了陌生领域就不准了（+0.269，未达统计显著——但注意，样本只有34个，这种样本量本来也只能可靠发现0.47以上的相关）。
- 事后补救失败了：用旧考卷定的容错线，放到新题型上全都偏窄（覆盖率只有0.62 - 0.77，应达0.95）；而用“新题型模拟卷”定的容错线虽然够宽（覆盖率100%），但宽到接近整个分数范围（半宽2.98，全数据范围才6.58）——等于没说。根因：新题型在“复习地图”（杠杆/适用域）上看起来毫不陌生（越界比例0%），警告系统完全没响。
- 所以正确的做法是事前立规矩而不是事后打补丁：双划分报告制度 + 三级“陌生度”标注（域内高置信72个/域内低置信32个/域外预警27个）+ 小样本收缩修正，据此对131个中药成分排出可信的优先级：黄连、苦参、甘草、丹参构成第一梯队。

所有数字的真实性：每个数字都能追溯到版本化数据文件（附表S0），核心统计量另用 MATLAB 独立重算一遍，与 Python 结果逐位一致（ $R^2=0.7898/-0.6101$ ，Spearman=0.7681/0.5328 等，见2.9节）。

摘要

机器学习虚拟筛选天然产物时，几乎都用“随机划分”来验证模型——这隐含了一个假设：待筛选的新分子和训练分子长得差不多。本文用一套“双划分审计”直接检验这个假设：在354个经严格清洗的法尼醇X受体（FXR）结合活性化合物上训练贝叶斯图神经网络（GNN），随机划分下 $R^2=0.790$ 、 $\text{RMSE}=0.723$ 、 $\text{Spearman } \rho=0.768$ （ $n=36$ ）；换成Bemis–Murcko骨架划分（考题全是没见过的骨架），同一模型崩塌至 $R^2=-0.610$ ，且指纹基线同样崩塌（随机森林0.047，XGBoost-0.127）——崩塌与架构无关，排序信息部分存活（ ρ 0.48–0.64）。不确定度 σ 在域内有效（检验集口径 $\rho=+0.585$ ， $p=1.8\times10^{-4}$ ），域外未证（+0.269， $p=0.124$ ；该样本量最小可检相关约0.47）；名义95%区间在骨架测试集上仅覆盖73.5%（Wilson 95%CI 56.9%–85.4%）。事后校准系统性失败：以域内数据校准的杠杆膨胀 σ 与共形方法覆盖率仅0.618–0.765，根因是骨架位移在描述符空间杠杆上不可见（骨架测试集平均杠杆0.0096反而低于域内校准集0.0126，两组越界比例均为0%；杠杆与误差的秩相关为-0.325/-0.189）；以骨架匹配数据校准的共形区间覆盖率达标（点估计1.000，Wilson下界89.9%，满足预置的 ≥ 0.90 验收标准；但样本量无法区分0.90与0.95），代价是平均半宽2.98个 pIC_{50} 单位——接近数据全域（3.38–9.96），放弃排序分辨率。结论：外推失效不可事后修复，只能事前披露。本文将披露制度化可为可执行流程——双划分报告、不确定度口径标签、三级适用域标注与置信度加权的收缩修正评分（CW-BCS）——并对131个中药成分给出优先级：黄连、苦参、甘草、丹参的第一梯队身份在收缩参数 $k=3-12$ 内稳定。全部计算可复现（GEO GSE135251；ChEMBL ChEMBL2047；PubChem；RCSB PDB；KEGG）。

1 引言

代谢相关脂肪性肝炎（MASH）仍是肝病领域最大的未满足临床需求之一。2024年甲状腺激素受体 β （THR- β ）激动剂瑞司米罗获批是里程碑，但单药局限——FXR激动剂接连折戟、单轴药物效应有限——使“多靶点温和协同”的天然产物路线持续受到关注。计算筛选便宜快捷，却有一个结构性弱点：公共活性数据库以合成药物化学骨架为主，天然产物住在另一片化学空间里。

由此产生两个失败模式。第一，点预测模型（QSAR、指纹回归、图神经网络）习惯用随机划分验证，相当于“做过的原题换个数字再考”；而真实筛选面对的是新骨架，相当于“考新题型”。报告的成绩因此系统性高估了前瞻表现。第二，不确定性量化（UQ）方法（MC失活、深度集成）承诺标记不可靠的预测，但它们的校准也通常在同样的“熟题”上评估，在外推场景下的行为缺乏记录。

本文问一个刻意简单的问题：当贝叶斯GNN被放到骨架级外推的审计下，还有什么能活下来——活不下来的部分，事后校准能补救吗？四个贡献：

1. 把“天然产物会过度外推”的担忧变成测量事实：双划分协议下， R^2 从0.79跌到-0.61，三种模型族同崩；
2. 不确定度的诚实分解：域内有效、域外未证，全程带口径标签（检验集/合并集）与Wilson区间；
3. 一个系统性负结果：域内数据的事后校准全部失败（根因：骨架位移对杠杆不可见）；骨架匹配的共形校准虽达验收标准，但区间宽度摧毁分辨率——统计有效性与排序分辨率不可兼得；
4. 可操作的披露纪律：三级标注 + 收缩修正的CW-BCS评分，产出十味中药的可辩护排序与九个证据分级候选。

2 方法

全部计算以Python脚本执行于单台桌面CPU；本文每一个数字都对应一个版本化结果文件（附表S0），核心统计量另经MATLAB独立复算。

2.1 疾病靶点的患者数据验证

从GEO获取MASH肝转录组数据集GSE135251（RNA-seq，216例肝活检：正常10例、单纯脂肪肝51例、MASH 155例，含纤维化分期）。计数经DESeq2中位数比值法标准化；差异表达用对数计数上的Welch t检验加Benjamini-Hochberg假发现率（FDR）控制。通路富集用KEGG（人类通路）。阳性对照基因（FASN、CYP7A1、COL1A1、TNF）在查看结果前预先指定——先立标准再看数据，防止“事后挑好看的”。

2.2 FXR数据集构建与适用域参考

重要口径：从ChEMBL（ChEMBL2047，人源FXR）下载的是结合活性（IC₅₀型）记录（精确 '=' 关系、纳摩尔单位、体外生化测定）——模型学习的是“结合强弱”，不区分激动还是拮抗，这一局限贯穿全文（见2.7与局限性）。

清洗流程：548条原始记录 → 盐剥离/混合物剔除、保留精确关系449条 → 规范SMILES去重（重复测定取均值，最多7次）367条 → PAINS干扰物剔除9条 → 主成分/杠杆适用域（AD）过滤剔除4个超阈样本（ $h > h^* = 3(k+1)/n = 0.0503$ ， $k=5$ 个主成分，参考空间基于358个化合物）→ 最终354个化合物（pIC₅₀范围3.38 - 9.96；长尾分布：低于5的有87个，高于9的仅13个）。需要说明：AD参考空间拟合于剔除前数据（ $n=358$ ），其中包含日后用作测试的化合物——杠杆值存在自参照偏差、可能整体偏低，这作为局限性如实报告（见第6节）。

2.3 贝叶斯图神经网络（完整超参数）

分子表示为图（原子特征：元素、度、形式电荷、总氢数、杂化方式、芳香性、成环；键：类型）。模型为3层GIN（隐藏层96维）+ BatchNorm + 双头输出（均值 μ 与对数方差 $\log \sigma^2$ 偶然项），用异方差高斯NLL损失训练；加权损失：pIC₅₀按分箱边界（5, 6, 7, 8, 9）分箱，样本权重=1/所在箱频次并归一化为均值1（界外样本并入首/末箱）——防止模型无视稀有的高活性样本。推理时保持失活层激活（MC失活， $T=50$ 次前向），五种子集成（42/7/2024/11/99）： μ 取集成均值；总 σ 综合平均偶然方差、平均认知方差与种子间 μ 方差。训练协议：Adam学习率 5×10^{-4} 、权重衰减 10^{-6} 、批大小64、至多500轮、验证RMSE早停（耐心60轮）。生产模型（用于中药库推理）：在全量354化合物上按同一协议五种子重训，以固定10%内部保留集（种子42划分）做早停、保留各种子最优状态。

2.4 双划分评估协议

每次随机划分（80/10/10，种子42）配一次同数据的Bemis-Murcko骨架划分：骨架按所属化合物数从大到小贪心分配到训练（80%）/验证（10%）/测试（10%），保证每个测试骨架在训练中从未出现。两种划分用完全相同的指标与指纹基线（Morgan半径2、2048位；随机森林800棵树；XGBoost匹配预算）。

2.5 不确定度指标与事后校准（口径纪律）

所有不确定度统计量带口径标签：检验集口径从留出测试集的逐化合物预测重算（本文主口径）；合并口径（验证+测试，训练期早停循环的存储值）只入脚注——早停用了验证集，合并值偏乐观（骨架情形下两个口径甚至反号，这本身就是对合并报告的警示）。覆盖率为 $|\text{误差}| \leq 1.96\sigma$ 的比例，每个覆盖率配Wilson 95%区间与样本量。

校准实验：以随机划分测试集（ $n=36$ ，域内）为校准集、骨架划分测试集（ $n=34$ ，域外）为评估集：

- M0 原始 σ 区间;
- M1 杠杆膨胀 σ : $\sigma_{\text{inf}} = \sigma \cdot \sqrt{(1+h/h^*)}$ (h 为化合物在AD参考空间的杠杆);
- M2 平坦分裂共形: 校准集绝对残差的有限样本修正 $(1-\alpha)$ 分位数, 作为常数半宽;
- M3/M4 自适应与杠杆加权的z分数共形变体 (附表S1);
- M5 骨架匹配共形: 载入已保存的骨架划分五种子集成, 对其骨架验证折 ($n=36$) 真实推理 (复现保真度: μ 与存储测试预测的Pearson $r=0.9997$), 在该折上取共形分位数。

2.6 中药成分库与三级标注

药材范围表述 (安全性优先): 本文研究用中药共10味, 系文献调研选定的传统肝相关药材; 其中2味需特别毒性限定——雷公藤仅收录其非毒性成分 (毒性成分按预设清单排除, 且其排名经小样本收缩修正后已跌至第9); 原调研中出现的千里光因含吡咯里西啶生物碱 (PA) 肝毒成分, 经PA药材前置黑名单 (千里光、款冬、菊三七等PA属药材一律过滤) 剔除, 未进入本化合物库。

233个成分条目经PubChem逐条解析 (每个化合物记录CID可溯源), ADMET过滤 ($150 < \text{分子量} < 500$, $\text{LogP} < 5.5$, 氢键供体 ≤ 5 , 受体 ≤ 10) 与预设排除清单后余131个化合物。证据基线是带CID锚定的131化合物表; 一次覆盖中间文件的运维事故与数据链重建过程在附表S3如实记录 (重建后解析224、过滤131, 与历史CID一致率129/131, 2处差异为PubChem标识符版本更新)。每个化合物由生产集成推理 (MC T=50) 并按双层规则标注三级: 域内高置信 ($h \leq h$ 且 $\sigma \leq 0.70$)、域内低置信 ($h \leq h$ 且 $\sigma > 0.70$)、域外预警 ($h > h^*$)。

2.7 CW-BCS评分: 置信度加权结合覆盖 (含收缩修正)

$\text{CW-BCS} = [(w \cdot s_{\text{FXR}}) \cdot s_{\text{THRB}} \cdot s_{\text{ACC}}]^{(1/3)}$, 置信权重 $w=1/(1+\sigma)$; 三靶分数先经最小-最大归一化。语义边界 (前置声明): CW-BCS度量的是 "在所选靶点面板上的结合覆盖倾向", 不是药理协同, 且以面板为条件; 模型只学 "结合强弱", 不区分激动/拮抗——药效方向需实验判定。 s_{FXR} 来自GNN预测 μ ; s_{THRB} 与 s_{ACC} 来自AutoDock Vina对接能 (避免小样本强行建模)。结构冗余惩罚: 每味药前3成分的两两Morgan Tanimoto相似度均值超过0.6的部分线性罚分 (封顶0.5)。药材级分数做经验贝叶斯收缩 $s \times n/(n+5)$ (惩罚成分数少的药材); 代表成分置信硬约束: 展示的代表成分必须为域内高置信 (否则双代表并列标注)。绝对活性标志层 ($\text{FXR } \mu \geq 6.5$ 或 $\Delta G \leq -7 \text{ kcal/mol}$) 与排名分开报告。

2.8 分子对接

AutoDock Vina 1.2.5; 受体3FLI/10SH (FXR)、3GWS (THR- β)、5KKN/3GID (ACC2), 单链清洗+Gasteiger电荷, 对接盒以共晶配体为中心。流程先过重对接门控 (4个共晶配体RMSD 0.33 - 1.22 Å, 全部 $< 2 \text{ Å}$), 再以阳性对照药理排序校验 (GW4064 -9.70、丹参酮IIA -9.73、CDCA -8.70、OCA -6.77 kcal/mol; 瑞司米罗 -10.11 $> T3$ -9.52; ND-646 -10.52)。已知工具偏差如实声明: Vina对甾体骨架 (如OCA) 系统性打分偏低, 本文结论只依赖同库内相对比较。

2.9 可复现性与MATLAB独立复算

每个图表由编号脚本从公共原始数据再生 (GEO/ChEMBL/PubChem/PDB/KEGG登录号见数据可用性)。核心统计量另以MATLAB从零独立实现复算 (含手写秩相关函数): $R^2=0.7898/-0.6101$ 、

RMSE=0.7228/1.2900、Spearman $\rho(\mu, y)=0.7681/0.5328$ 、 $\rho(\sigma, |\text{误差}|)=0.5853/0.2688$ 、95%覆盖率=1.0000/0.7353、M2共形分位数 $q=1.5107$ 及其覆盖率0.7059——与Python结果逐位一致 (results/v6/matlab_verify.csv)。本研究新增脚本: v6_conformal.py (M0-M4)、v6b_scaffold_val_conformal.py (M5)、verify.m (MATLAB复算)、fix_v5_cwbc_sroundtable.py (收缩与代表成分修正)。

3 结果

3.1 靶点面板获患者数据支持

GSE135251中,四个目标基因在MASH组($n=155$)对比正常组($n=10$)时全部显著差异(表1): FXR (NR1H4) -0.285 (校正 $p=1.03 \times 10^{-2}$)、THR- β (THRB) -0.315 (1.99×10^{-2})、ACG1 (ACACA) $+0.897$ (7.42×10^{-5})、ACC2 (ACACB) $+0.631$ (4.23×10^{-3})。预先指定的阳性对照全部方向正确 (FASN $+2.47$; CYP7A1 $+2.16$, 与FXR去抑制一致; COL1A1 $+1.04$ 且与纤维化分期相关 $\rho=0.431$; TNF $+1.09$), 全分析共3,909个差异基因(上调1,962/下调1,947)。KEGG富集第一名是胆汁分泌通路(hsa04976, 名义 $p=8.6 \times 10^{-4}$)——由于约30%的检测基因为差异基因、多重校正稀释, FDR校正后($p_{\text{adj}}=0.28$)未达显著, 本文只作名义富集报告, 不进摘要。

3.2 换成"新题型", 点预测全线崩塌

表2与图1给出双划分审计。随机划分下贝叶斯GNN表现优秀($R^2=0.790$; RMSE=0.723; Spearman $\rho=0.768$, $p=4.6 \times 10^{-8}$; $n=36$), 满足预设契约指标。骨架划分下同一流程崩塌至 $R^2=-0.610$ (RMSE=1.290)——通俗地说, 还不如直接猜平均分。崩塌在受试的三种模型族中全部出现(随机森林 $0.845 \rightarrow 0.047$; XGBoost $0.811 \rightarrow -0.127$), 说明这是数据分布的问题而非特定架构的问题(限于单数据集、单随机种子的证据强度, 见第6节)。值得注意的是排序信息部分存活(骨架划分 Spearman ρ : BGNN 0.533、随机森林0.641、XGBoost 0.483, 均 $p<0.01$)——而排序恰是筛选真正消费的东西, 故本文全文同时报告 R^2 与 ρ 。

3.3 σ : 域内有效, 域外未证, 区间欠覆盖

检验集口径下, σ 与绝对误差的秩相关: 随机划分 $+0.585$ ($p=1.8 \times 10^{-4}$, $n=36$)——在熟悉领域, 模型越心虚的地方确实错得越多。骨架划分 $+0.269$ ($p=0.124$, $n=34$): 方向为正但未达显著。需要明确: "未证"不等于"无效"——功效分析表明, $n=34$ 、80%功效下最小可检相关约 $|\rho|=0.47$, $+0.269$ 在此样本量下本来就可能检不出。合并口径(随机 $+0.340$, $n=71$; 骨架 -0.027 , $n=70$)只入脚注: 早停用了验证集使合并值偏乐观, 骨架情形两口径甚至反号——这本身就是合并报告的危险示例。

名义95%区间: 随机划分测试集覆盖100% (Wilson 95%CI 90.5% - 100%, $n=36$ ——域内反而过宽、过度保守); 骨架划分测试集仅覆盖73.5% (Wilson 95%CI 56.9% - 85.4%, $n=34$)—— σ 在域内膨胀过度、域外膨胀不足, 区间两头都不合适。

3.4 事后校准: 补不回来, 因为杠杆"看不见"新题型

表3与图2给出校准实验。以域内数据(随机测试集)校准、在骨架测试集评估: 杠杆膨胀 σ (M1)把覆盖率从0.735提到0.765 (Wilson CI 60.0% - 87.6%)——注意34个样本下这只是多盖住1个化合物, 仍是显著欠覆盖; 平坦共形(M2) 0.706; 自适应与加权变体(M3/M4, 附表S1)反而跌到0.647

与0.618——域内残差根本没见过域外那种长尾误差，怎么加权都无济于事。

根因是结构性的，而且我们给它量了数字：骨架位移在杠杆空间里不可见。骨架测试集平均杠杆0.0096，反而低于域内校准集的0.0126；两组超过 $h^*=0.0503$ 的比例都是0%。更进一步，杠杆与预测误差的秩相关为：随机-0.325（ $p=0.053$ ）、骨架-0.189（ $p=0.285$ ）——杠杆高的分子并不更错（若说有什么趋势甚至是反向的）。换句话说：新骨架分子在二维描述符地图上看起来“毫不陌生”，但它所处的局部构效关系从未被学过。任何用这类协变量驱动的加权/膨胀，天然失明。

骨架匹配共形（M5）——载入骨架划分集成、在其骨架验证折（ $n=36$ ；该折 $R^2=0.153$ 、 $RMSE=0.875$ ，本身就是崩塌的）上真实推理并取分位数——覆盖率点估计1.000（Wilson 95%CI 89.9% - 100%），满足我们预置的 ≥ 0.90 验收标准；但诚实地说， $n=34$ 无法把0.90与0.95区分开，我们不声称“精确达到95%”。更重要的是代价：平均半宽2.98个 pIC_{50} 单位（ z 分数变体5.18 - 5.22，附表S1），而全数据范围才6.58（3.38 - 9.96）——区间宽到等于没说：一个“预测活性 6.5 ± 3.0 ”的候选毫无排序价值。统计有效性与排序分辨率，在外推场景下不可兼得。

3.5 把披露做成纪律：131个成分的三级标注

既然修复无望，就把披露制度化。生产集成对131个库成分标注（图3）：域内高置信72个、域内低置信32个、域外预警27个。域内高置信层富集黄连的原小檗碱型生物碱簇（如小檗碱预测 $\mu=8.21$ ——注意这只说明“预测结合强且模型不心虚”，不区分激动/拮抗，与小檗碱大量代谢药理文献的方向一致性只是事后观察，不作因果声称）与五味子木脂素。经3.4验证的纪律：域外成员按标注层级硬门控、逐出优先队列——而不是按 σ 大小连续降权，因为域外 σ 本身可能虚小、反而麻痹大意；置信权重 $w=1/(1+\sigma)$ 只在域内两层使用。

3.6 收缩修正后的中药排序

表4与图4给出排序。原始CW-BCS把只有2个成分的雷公藤排到第4、压过18个成分的丹参——这不合理，就像“只答对2题的考生平均分高”不能服众。收缩修正（ $s \times n/(n+5)$ ）后雷公藤0.565→0.162（第4→第9），第一梯队——黄连（0.529）、苦参（0.458）、甘草（0.443）、丹参（0.427）——身份保持（我们只主张梯队身份稳定，不主张梯队内1-4名的次序；敏感性分析见附表S2： $k=3/8/12$ 下前五名成员与次序均不变）。代表成分置信硬约束执行后：黄连代表从低置信的黄连碱改为高置信的表小檗碱（CW-BCS 0.710，原最佳降为次代表）；苦参改为苦参酮E；水飞蓟全部成分域外预警，整药材挂警示旗——水飞蓟因此成为“层级门控”的工作示例：计算上诱人，但被逐出优先队列。

作为数据驱动与物理打分的方向交叉验证：预测 μ 与Vina对接能在前10化合物上的秩相关，在3FLI晶体为 $\rho=-0.394$ （ $n=10$ ， $p=0.26$ ），在10SH晶体为 $\rho=-0.042$ （ $p=0.91$ ）——两个晶体结构给出的答案不一致，故此交叉验证只作探索性参考，不用于任何排名或权重。另有4个THR- β 对接能为正值（物理上不结合；柴胡皂苷元A/D/F、五味子醇A，均为底部条目）——标记保留、不删除（事后删数据比保留标记更不诚实），几何均值评分对它们不敏感（附表S5）。

3.7 候选与对照证据表

表5整合九个条目，表名强调含对照档。要点：樟芝簇（_antcin K、antrodin B、antrocinnamomin F_）锚定在物种级临床证据——28例双盲安慰剂对照试验用的是菌丝体全粉、血清学肝评分终点（PMID 32657670）——外加计算行支持；粉末级证据不归因到单体，且完整对接存

档仅antrocinnamomin F一行, antcin K/antrodin B的证据列如实标注为"物种级+计算行"。积雪草积雪草酸以直接机制文献入列 (TGF- β /Smad与肝星状细胞抑制, PMID 35963324), 明确标注在本面板中无计算分 (其0.32的"分数"只是证据项得分, 与0.859不可比)。表小檗碱代表纯计算高置信层; 小檗碱兼任阳性对照锚; 甘草Derrone与白花蛇舌草Anthraxin是可购的纯计算候选; 真菌代谢物07H239-A仅作计算对照——其来源菌株不在公共菌种保藏中心 (ATCC/NRRL均无), 且发现论文标题即"细胞毒" (PMID 15387660)。全部排序均为计算优先级、需实验验证; 不对任何化合物作疗效声称。

4 讨论

中心发现是一个信息论式的事实。随机划分指标回答的是"模型内插得好不好"——而筛选从来不问这个问题。骨架划分审计回答的是"模型遇到真正的新骨架会怎样"——答案是: 三种受试模型族全部从"优秀"跌到"不如猜均值", 有用信号只剩部分排序信息 ($\rho \approx 0.53$)。更关键的是, 这场崩塌不伴随任何杠杆空间特征 (3.4节: 杠杆与误差零相关甚至负相关), 因此无法被检测、也无法被事后修复。共形方法继承了它想修复的那个可交换性假设: 域内校准的区间欠覆盖 (0.618 - 0.765); 骨架匹配校准的区间有效但宽度接近全数据范围 (半宽2.98对6.58)。诚实区间和有用区间在外推下分道扬镳, 没有事后程序能弥合——只有新数据 (或新训练骨架) 能。

活下来的东西成为交付物。既然修复不可能, 就把披露工程化进流程: (i) 双划分指标作为默认报告标准, R^2 与 ρ 并报 (排序部分存活); (ii) 不确定度口径显式化——本文合并口径与检验集口径在骨架情形甚至反号, 说明合并早停统计量会误导; (iii) 三级适用域门控, 域外成员按规则逐出优先队列而非按 σ 大小 (欠膨胀的域外 σ 可能虚假地小); (iv) 聚合分数的小样本护栏 (收缩、代表成分置信约束)——2个成分的药材不应排在18个成分之前。

关于"随机森林点精度更高为何还用GNN"。随机森林随机划分 R^2 (0.845) 确实高于GNN (0.790), 我们毫无尴尬地报告这一点。保留GNN的原因: 交付物是逐分子的校准不确定度与原子级可解释性 (GNNExplainer归因集中在原小檗碱的季铵氮与异喹啉核——化学上合理的药效团), 而非点精度; 且集成MC失活的 σ 在域内确实给误差排序 (+0.585), 这是无方差基线给不了的。骨架划分下两族架构的点预测同样不可用——约束条件是数据覆盖, 不是模型类别。

药理语义与边界。CW-BCS是面板条件的结合覆盖倾向分: 对机制 (激动/拮抗) 故意不可知、不作协同声称、继承Vina对甾体/大环的打分偏差。中药排序是实验分诊的优先级——表5直接给出经济的第一轮湿实验设计 (4个可购标样+HepG2脂变模型+甘油三酯下降与活力双门控), 作为计算管线的外部校准回路。面板上得分低的药材 (五味子、灵芝) 不因此被"否定": 面板不含它们的主要作用轴 (如Nr1f2), 低分应解读为"面板外"而非"无效"。

5 结论

在模拟真实筛选的审计下——直面新骨架——点预测虚拟筛选崩塌 (R^2 0.79 $\rightarrow$ -0.61) 且与架构无关; 随机划分下看似校准良好的不确定度, 域外既欠覆盖 (73.5%) 又抗拒事后修复, 因为骨架新颖性在描述符杠杆上不留痕迹。骨架匹配的共形校准能达覆盖率验收标准 (点估计100%, CI下界89.9%), 代价是牺牲使筛选有意义的分辨率 (半宽 ≈ 3 对全域6.6)。可行的策略是把披露做成流程: 双划分报告、口径标签、规则式适用域门控——应用于131个中药成分, 产出收缩修正、置信约束的优先级 (黄连 - 苦参 - 甘草 - 丹参第一梯队; 九个证据分级条目)。我们把这套审计协议作为机器学习天然产物筛选的最低报告标准提出, 把三级标注作为它的操作产出。

6 局限性（10条，按诚实标准）

1. 无湿实验验证：全部候选声称均为计算优先级。
2. 单一建模靶点：FXR数据是建模基底；多靶点QSAR扩展需先逐靶补骨架验证。
3. 样本量：354个化合物、测试集36/34——所有覆盖率带Wilson区间；骨架 σ -误差相关 (+0.269) 为未证而非无效（最小可检 $|\rho| \approx 0.47$ ）。
4. 验证折双重角色：骨架验证折兼作早停折，合并口径因此偏乐观；本文以检验集口径为主报告缓解。
5. 自参照杠杆：AD参考空间含日后测试化合物，杠杆可能整体偏低——“杠杆盲度”结论在其之下只会更强，但绝对杠杆值应谨慎解读。
6. 共形可交换性近似：骨架贪心分组非严格随机分组，M5的覆盖保证是近似的；且骨架测试与验证折的z分布存在重尾失配（80%档覆盖率仅0.618，附表S1）。
7. 收缩参数k=5为合理缺省：k=3-12下结论稳定（附表S2），但k的选择本身无唯一准则。
8. 单次随机划分（种子42）：划分重采样会收紧区间估计。
9. Vina打分偏差（甾体/大环）：结论只依赖库内相对比较；交叉对接跨晶体不一致（3FLI vs 10SH），仅探索性使用。
10. 131化合物库是十味药成分空间的非穷尽子集；且模型不区分激动/拮抗，药效方向待实验。

数据与代码可用性

全部数据公开：RNA-seq为GEO GSE135251；FXR活性为ChEMBL CHEMBL2047（REST API，体外生化测定）；化合物标识与结构为PubChem PUG-REST（逐化合物CID存档）；受体结构为RCSB PDB（3FLI、10SH、3GWS、5KKN、3GID）；通路注释为KEGG REST。逐化合物预测、杠杆、校准结果（results/v6，含MATLAB复算输出）与分析脚本可从通讯作者获取，录用后公开存档（Zenodo）并回填DOI。

作者贡献与利益冲突

王启龙与姜希伟设计研究；课题组以内部“红队圆桌+独立复算”机制对全部结论做过压力测试后成文。全体作者已阅读并批准稿件。作者声明无竞争性经济利益。

缩略语

MASH（代谢相关脂肪性肝炎）；FXR（法尼醇X受体）；THR- β （甲状腺激素受体 β ）；ACC（乙酰辅酶A羧化酶）；GNN（图神经网络）；UQ（不确定性量化）；AD（适用域）；CW-BCS（置信度加权结合覆盖评分）；DEG（差异表达基因）；PAINS（泛测定干扰化合物）；PA（吡咯里西啶生物碱）。

表格

表1 靶点面板的病理学验证（GSE135251，MASH组 $n=155$ vs 正常组 $n=10$ ；数据集共216例）

基因（蛋白）	log2倍数变化	校正p值	解读
NR1H4（FXR）	-0.285	1.03×10^{-2}	受体下调
THRB（THR- β ）	-0.315	1.99×10^{-2}	受体下调
ACACA（ACC1）	+0.897	7.42×10^{-5}	脂合成上调
ACACB（ACC2）	+0.631	4.23×10^{-3}	脂合成上调

基因 (蛋白)	log2倍数变化	校正p值	解读
FASN (对照)	+2. 47	—	方向符合预期
CYP7A1 (对照)	+2. 16	—	FXR去抑制
COL1A1 (对照)	+1. 04	—	纤维化 (与分期 $p=0.431$)
TNF (对照)	+1. 09	—	炎症

表2 双划分审计 (同一数据、同一指标; 骨架划分下所有测试骨架训练中未出现)

模型	划分	R ²	RMSE	MAE	Spearman ρ
贝叶斯GNN	随机 (n=36)	0. 790	0. 723	0. 592	0. 768
贝叶斯GNN	骨架 (n=34)	-0. 610	1. 290	1. 039	0. 533
随机森林	随机	0. 845	0. 620	0. 498	0. 811
随机森林	骨架	0. 047	0. 992	0. 713	0. 641
XGBoost	随机	0. 811	0. 686	0. 507	0. 820
XGBoost	骨架	-0. 127	1. 079	0. 803	0. 483

人话解读: 左列"随机"成绩都体面; 右列"骨架"三种模型全崩——换个划分方式, 成绩单就变了, 说明平时报告的随机划分成绩高估了真实筛选表现。但 ρ 一行说明"排序眼光"还在 (0. 48 - 0. 64), 筛选主要用排序。

表3 事后校准的95%区间 (在骨架测试集=域外, n=34上评估)

方法	校准来源	覆盖率 (Wilson 95%CI)	平均半宽 (plC□□)
M0 原始 σ	— (训练即得)	0. 735 (0. 569 - 0. 854)	1. 66
M1 杠杆膨胀 σ	— (参数式膨胀)	0. 765 (0. 600 - 0. 876)	1. 80
M2 平坦分裂共形	随机测试集 (n=36, 域内)	0. 706 (0. 538 - 0. 832)	1. 51
M5 骨架匹配共形	骨架验证折 (n=36, 域外同类)	1. 000 (0. 899 - 1. 000)	2. 98

人话解读: 前三行都是"用旧考卷定容错线"——到新题型上全都偏窄 (覆盖率不到0. 77, 达标线0. 95); 第四行换了"新题型模拟卷"来定线, 够宽了 (覆盖率100%), 但宽到接近整个分数范围 (半宽2. 98 vs 全域6. 58), 失去了排序价值。(M3/M4见附表S1: 0. 647/0. 618。)

表4 收缩修正后的CW-BCS中药排序 (含代表成分置信约束)

排名	药材	成分数	原始分	收缩分	代表成分 (置信层级)
1	黄连 <i>Coptis chinensis</i>	14	0. 718	0. 529	表小檗碱 (域内高置信)
2	苦参 <i>Sophora flavescens</i>	18	0. 585	0. 458	苦参酮E (域内高置信)
3	甘草 <i>Glycyrrhiza uralensis</i>	18	0. 566	0. 443	甘草黄酮 (域内高置信)
4	丹参 <i>Salvia miltiorrhiza</i>	18	0. 545	0. 427	Salvilenone (域内高置信)
5	青蒿 <i>Artemisia annua</i>	23	0. 456	0. 375	Chrysosplenol D (并列高置信代表+域外参考)
6	水飞蓟 <i>Silybum marianum</i>	11	0. 415	0. 285	全成分域外预警 (整药材警示旗)
7	五味子 <i>Schisandra chinensis</i>	18	0. 354	0. 277	五味子丙素 (域内高置信)

排名	药材	成分数	原始分	收缩分	代表成分 (置信层级)
8	灵芝 Ganoderma lucidum	6	0.406	0.221	灵芝酸C (域内高置信)
9	雷公藤 Tripterygium wilfordii	2	0.565	0.162	雷公藤醌醇 (收缩后第4→第9; 仅非毒性成分入库)
10	柴胡 Bupleurum chinense	3	0.107	0.037	柴胡皂苷元F (域内高置信)

人话解读：竖线标记的是收缩前的分数——雷公藤原来排第4，"只答对2题"经不起收缩修正；前四名成员在k=3 - 12全范围稳定。

表5 候选与对照证据表 (全部为计算优先级，不作疗效声称)

条目 (来源)	证据等级	模型层级	可购性	锚点
Antcin K (樟芝)	物种级临床证据+计算行	可计算	有标样	PMID 32657670
Antrodin B (樟芝)	物种级临床证据+计算行	可计算	有标样	PMID 32657670
Antrocinnamomin F (樟芝)	物种级临床证据+完整计算存档	可计算 (统一板块 0.859)	有标样	PMID 32657670
积雪草酸 (积雪草)	直接机制文献 (纤维化轴)	本面板无计算分 (证据型入列)	有标样	PMID 35963324
表小檗碱 (黄连)	纯计算	域内高置信	药材可得	CW-BCS 0.710
小檗碱 (黄连)	已知机制锚 (方向不可知)	域内高置信 ($\mu=8.21$)	有标样	文献4
Derrone (甘草)	纯计算	可计算	药材可得	统一板块0.786
Anthraxin (白花蛇舌草)	纯计算	可计算	药材可得	统一板块0.792
07H239-A (炭角菌科真菌)	仅计算对照 (来源论文即细胞毒; 菌株不在公共保藏中心)	可计算	不可购	PMID 15387660

注：积雪草酸的0.32只是证据项得分，与0.859的计算分不可直接比较；水飞蓟宾为域外门控工作示例 (计算诱人但逐出优先队列)。

图注

Same model, same data, different split: point accuracy collapses under scaffold extrapolation




图1 双划分审计 (贝叶斯GNN, 354个FXR化合物)。左: 随机划分 ("做过的题型", $n=36$); 右: 骨架划分 ("全新题型", $n=34$)。点为实测对预测 pIC_{50} ; 须为名义95%区间 ($\mu \pm 1.96\sigma$)。同一模型, 换种考法, 成绩从 $R^2=0.790$ 跌到 -0.610 ; 但点的上下次序 (排序) 部分保住 (ρ 0.768 $\rightarrow$ 0.533)。

Post-hoc recalibration from in-domain data cannot restore coverage; matched-domain conformal does, at the cost of resolution




图2 事后校准实验 (骨架测试集 $n=34$; 各方法校准来源见括号)。(a) 95%覆盖率与Wilson区间、名义线0.95: 域内校准的三种方法 (M0/M1/M2) 显著低于名义线; 骨架匹配共形 (M5) 点估计1.000。(b) 代价: 平均半宽——M5的2.98已接近全数据范围 (3.38 - 9.96), "有效的区间"宽到失去排序价值。




图3 131个中药成分的三级标注（柱，左轴）与各层中位 σ （线，右轴）。纪律：域外成员按层级逐出优先队列，不看 σ 大小——因为域外 σ 可能虚小。




图4 收缩修正后的CW-BCS中药排序 ($s \times n / (n + 5)$)；竖线为收缩前分数。雷公藤（2个成分）从第4跌到第9；第一梯队保持。柱色：代表成分置信状态。

附录：术语表（按正文出现顺序）

术语	英文/缩写	一句话解释
虚拟筛选	virtual screening	用计算机模型从大量分子中挑出可能有效的候选
MASH	metabolic dysfunction-associated steatohepatitis	代谢相关脂肪性肝炎，脂肪肝的炎症进展型
FXR	farnesoid X receptor	法尼醇X受体，胆汁酸与脂代谢的核受体
pIC ₅₀	—	活性浓度的负对数，数值越大活性越强
图神经网络	GNN	把分子当作“原子为点、化学键为边”的图来学习的模型
随机划分	random split	训练/测试集随机抽取——考的是“做过的题型”
骨架划分	scaffold split	按分子骨架分组划分——测试集全是训练没见过的骨架
分子骨架	scaffold	剥掉侧链后分子的核心框架
R ²	决定系数	预测解释实测方差的比例；为负=不如直接猜均值
RMSE	root mean squared error	平均误差大小（单位同pIC ₅₀ ）
Spearman ρ	秩相关	只看排序一致性的相关系数，筛选最关心它
不确定性量化	UQ	让模型同时报出“答案”和“对这个答案有多没底”
MC失活	MC-dropout	推理时保留随机失活、多次前向取散布，近似贝叶斯
σ	预测不确定度	模型自报的误差幅度，即“心虚程度”
覆盖率	coverage	真值落在预测区间内的比例；95%区间应覆盖95%
Wilson区间	Wilson CI	小样本下更可靠的比率的置信区间
共形预测	conformal prediction	用校准集误差分布给出带覆盖率保证的区间
可交换性	exchangeability	校准与评估数据同分布——共形保证成立的前提
杠杆	leverage	化合物在描述符空间离训练集“重心”的远近
适用域	AD, applicability domain	模型可靠适用的化学空间范围
PAINS	pan-assay interference compounds	常在多种实验里“假装有活性”的干扰结构
PA生物碱	pyrrolizidine alkaloids	吡咯里西啉生物碱，一类已知肝毒成分
ADMET	—	吸收/分布/代谢/排泄/毒性的成药性粗筛
CW-BCS	confidence-weighted binding-coverage score	本文提出的置信度加权多靶点结合覆盖评分

术语	英文/缩写	一句话解释
经验贝叶斯收缩	shrinkage	按样本量把极端分数往整体均值方向拉回的修正
Tanimoto相似度	Tanimoto similarity	两个分子指纹的重合程度, 用来惩罚结构雷同
阳性对照	positive control	已知有效的参照物, 用来验证实验/流程靠谱
GNExplainer	—	指出模型预测最依赖哪些原子/子图的可解释性方法

参考文献

1. Govaere O, et al. Transcriptomic profiling across the nonalcoholic fatty liver disease spectrum reveals gene signatures for steatohepatitis and fibrosis. *Sci Transl Med.* 2020, 12: eaba4448. (GSE135251; PMID 33268509)
2. Harrison SA, et al. A phase 3, randomized, controlled trial of resmetirom in nonalcoholic steatohepatitis with liver fibrosis. *N Engl J Med.* 2024, 390: 497–509.
3. Neuschwander-Tetri BA, et al. Farnesoid X nuclear receptor ligand obeticholic acid for non-cirrhotic, non-alcoholic steatohepatitis (FLINT). *Lancet.* 2015, 385: 956–965.
4. Kong W, et al. Berberine is a novel cholesterol-lowering drug with a unique mechanism of action. *Nat Med.* 2004, 10: 1344–1351.
5. Gaulton A, et al. ChEMBL: a large-scale bioactivity database for drug discovery. *Nucleic Acids Res.* 2012, 40: D1100–D1107.
6. Kim S, et al. PubChem 2023 update. *Nucleic Acids Res.* 2023, 51: D1373–D1380.
7. Berman HM, et al. The Protein Data Bank. *Nucleic Acids Res.* 2000, 28: 235–242.
8. Kanehisa M, Goto S. KEGG: Kyoto Encyclopedia of Genes and Genomes. *Nucleic Acids Res.* 2000, 28: 27–30.
9. Bemis GW, Murcko MA. The properties of known drugs. 1. Molecular frameworks. *J Med Chem.* 1996, 39: 2887–2893.
10. Sheridan RP. Time-split cross-validation as a method for estimating the performance of predictive models. *J Chem Inf Model.* 2013, 53: 783–790.
11. Baell JB, Holloway GA. New substructure filters for removal of pan assay interference compounds (PAINS). *J Med Chem.* 2010, 53: 2719–2740.
12. Tropsha A. Best practices for QSAR model development, validation, and exploitation. *Mol Inform.* 2010, 29: 476–488.
13. Xu K, et al. How powerful are graph neural networks? *Proc ICLR.* 2019.
14. Fey M, Lenssen JE. Fast graph representation learning with PyTorch Geometric. *Proc ICLR Workshop.* 2019.
15. Gal Y, Ghahramani Z. Dropout as a Bayesian approximation. *Proc ICML.* 2016: 1050–1059.
16. Lakshminarayanan B, et al. Simple and scalable predictive uncertainty estimation using deep ensembles. *Proc NeurIPS.* 2017: 6402–6413.
17. Kendall A, Gal Y. What uncertainties do we need in Bayesian deep learning for computer vision? *Proc NeurIPS.* 2017: 5574–5584.
18. Papadopoulos H, et al. Inductive confidence machines for regression. *Proc ECML.* 2002: 345–356.
19. Tibshirani RJ, et al. Predictive inference with the jackknife+. *J R Stat Soc B.* 2019, 81: 1351–1386.

20. Angelopoulos AN, Bates S. Conformal prediction: a gentle introduction. Found Trends Mach Learn. 2023, 16: 494 – 591.

21. Love MI, Huber W, Anders S. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. Genome Biol. 2014, 15: 550.

22. Benjamini Y, Hochberg Y. Controlling the false discovery rate. J R Stat Soc B. 1995, 57: 289 – 300.

23. Eberhardt J, et al. AutoDock Vina 1.2.0. J Chem Inf Model. 2021, 61: 3891 – 3898.

24. Wilson EB. Probable inference, the law of succession, and statistical inference. J Am Stat Assoc. 1927, 22: 209 – 212.

25. Chiou Y-L, et al. Hepatoprotective effect of Antrodia cinnamomea mycelium in patients with nonalcoholic steatohepatitis: a randomized, double-blind, placebo-controlled trial. J Am Coll Nutr. 2021. (PMID 32657670; DOI 10.1080/07315724.2020.1779850)

26. Li Y, et al. Asiatic acid alleviates liver fibrosis via multiple signaling pathways based on integrated network pharmacology analysis and experimental validation. Eur J Pharmacol. 2022, 931: 175193. (PMID 35963324)

27. McDonald LA, et al. 07H239-A, a new cytotoxic eremophilane sesquiterpene from a marine-derived xylariaceous fungus. J Nat Prod. 2004, 67: 1565 – 1567. (PMID 15387660)

附录A 湿实验验证方案 (C1, 一页纸执行版)

定位：本方案是计算管线的外部校准回路——无论阳性或阴性结果都有价值（阳性→候选升级，阴性→修正模型与标注），同时回答“计算优先级能否经得起一个孔板的检验”。

项目	内容
首批化合物	antcin K、antrodin B、积雪草酸、小檗碱（均可在试剂平台购买标准品；小檗碱兼阳性对照锚）
细胞模型	HepG2 脂变模型：棕榈酸/油酸 2:1 混合脂肪酸 0.25 mM 诱导 24 – 48 h
浓度设计	0.1 / 1 / 10 / 30 μM 四点；DMSO ≤ 0.1%
主要读出	甘油三酯（TG）定量或 BODIPY 493/503 荧光
活力门控	CellTiter-Glo, 活力 ≥80% 方可计入 Hit 判定
Hit 标准	TG 较模型组下降 ≥30% 且活力 ≥80% 的最低浓度 ≤10 μM
阳性对照	小檗碱 10 μM; lovastatin 1 μM（脂合成轴验证）
阴性对照	等浓度 DMSO
机制跟进	对 Hit 行：qPCR 验证 FASN/SQLE（脂）与 COL1A2（纤维化）模块
预算与周期	约 1500 元（项目经费 4000 元内）；一学期
明确外置	AMLN 小鼠实验（需外部合作与追加经费，不进大创承诺）

辅助信息（SI）：表S0 数字-来源对照；表S1 校准变体；表S2 收缩敏感性；表S3 数据链事件；表S4 – S6 全表/对接细节/可解释性。见 supporting_information.md。