

# 智慧筛选 CADD

基于贝叶斯图神经网络的  
抗MASH天然药物筛选项目

项目类别：创新训练项目

指导老师：姜希伟

项目负责人：王启龙

项目组成员：衣思淼 代维斯丹 宁显洸 王散曼

# 目录CONTENT

01 项目背景

02 研究内容

03 研究目标

04 研究方法

05 可行分析

06 项目创新






# MASH 研究现状与药物研发需求

## MASH患者情况

未进展为肝硬化  
或肝细胞癌

70%



进展为肝硬化  
或肝细胞癌

20%

资料来源: Rinella et al., 2023

FAD

1.5亿

OCA

代谢相关脂肪性肝炎（Metabolic dysfunction-Associated Steatohepatitis, MASH），前称非酒精性脂肪性肝炎（NASH），是目前全球最主要的慢性肝病之一。MASH的发病机制复杂，涉及胰岛素抵抗、脂质代谢紊乱、氧化应激和肝脏炎症等多个病理过程。

FDA于2024年3月批准Resmetirom (Rezdiffra) 上市，成为首个获批的MASH治疗药物，靶向甲状腺素受体 $\beta$  (THR- $\beta$ )。此外，Obeticholic Acid (OCA) 作为FXR激动剂处于临床III期。然而，目前可用的治疗选择仍然极为有限，亟需探索具有多靶点协同效应的新型候选分子。

# 现有虚拟筛选方法的核心方法学瓶颈

## CADD天然产物筛选瓶颈

仅输出单一的点估计值，  
却不提供该预测值的统计置信度



## 模型局限

传统中药 信息学多对单体成分进行等权评估，忽视了不同成分预测置信度的客观差异，导致整体协同评估结论的可靠性难以保证

## 沉没成本

缺乏置信度评估导致筛选结果中高置信的真实活性分子与模型 外推产生的假阳性分子严重混杂，极大增加了下游实验验证的沉没成本

## 过度外推

公开数据库训练集以合成小分子为主，天然 产物的高结构多样性常导致模型陷入过度外推 (*Over-extrapolation*) 困境



研究点一

MASH 核心靶点的转录组学确证

前提

核对数据集的样本类型、物种、疾病分组及测序平台信息

目的

为后续"以 FXR 为建模主锚点、以 THR-β/ACC 为空间对接验证靶点"的筛选策略提供坚实的病理学依据

01

GEO 数据库获取 MASH 患者肝组织转录组数据集

03

组学层面确证 FXR、THR-β、ACC 等靶点在患者样本中的显著差异表达

数据集

组学

R语言

02

R 语言（DESeq2/limma）开展差异表达基因（DEGs）分析及通路富集

| 基因           | log <sub>2</sub> FC | 方向 | 意义               |
|--------------|---------------------|----|------------------|
| NR1H4 (FXR)  | -1.43               | 下调 | 确认FXR激活策略合理性     |
| THRB (THR-β) | -0.87               | 下调 | 支持THR-β激活干预      |
| ACACA (ACC1) | +1.21               | 上调 | 确认ACC过度活跃，抑制策略有效 |



## 研究点二

# 高质量活性数据集构建与前置适用域过滤

SMILES 标准化、PAINS 化合物过滤，并将 IC50 转化为 pIC50



针对数据的长尾分布特性，引入加权损失函数（Weighted Loss）以缓解模型对高活性稀有样本的忽视



利用 RDKit 提取 2D 物理化学描述符，基于 PCA/Leverage 方法构建适用域（AD）边界，剔除超域离群样本净化输入源，并为后续天然产物的域外预警确立参照基准



利用Python从 ChEMBL 数据库获取 FXR 纯化蛋白体外实验数据，已确证可获得高质量有效活性数据约 569 条



研究点三 

## 带不确定性量化的贝叶斯图神经网络构建



模型架构

输入层:

- 分子图 → 原子节点特征 (20维): 元素类型(10) + 度(1) + 形式电荷(1) + 氢原子数(1) + 芳香性(1) + 成环(1) + Gasteiger电荷(1) + 杂化方式(4)
- 描述符 → 189维2D RDKit描述符 + Morgan指纹(1024bit)

图卷积层:

GCNConv(20→128) → ReLU → Dropout(0.2)

GCNConv(128→128) → ReLU → Dropout(0.2)

GCNConv(128→128) → ReLU → Dropout(0.2)

全局池化:

global\_mean\_pool → 128维图向量

描述符分支:

Standard Scaler → PCA(n=40) → 40维描述符向量

融合全连接层:

concat[128 + 40 = 168] → Linear(168→128) → ReLU → Dropout(0.2) → Linear(128→1)

不确定性量化:

Monte Carlo Dropout (推理时保持Dropout激活, N=200次采样)

输出: pred\_mean\_pIC50, pred\_std\_pIC50, pred\_active\_prob = P(pIC50≥6.0)

| 参数                | 值                                 | 训练配置 |         |
|-------------------|-----------------------------------|------|---------|
| 训练策略              | 5折交叉验证, 取ensemble均值               |      |         |
| 优化器               | Adam (lr=1e-3, weight_decay=1e-4) |      |         |
| 损失函数              | MSE Loss                          |      |         |
| Epoch             | 200 (含早停, patience=30)            |      |         |
| Dropout           | 0.2                               |      |         |
| 批大小               | 64                                |      |         |
| 指标                | 模型评估结果 (测试集)                      |      | 达标      |
| R²                | 0.6083                            |      | ✓ ≥0.60 |
| RMSE              | 0.7491 kcal/mol                   |      | ✓ ≤0.80 |
| ECE               | 0.1130                            |      | ✓ ≤0.15 |
| F1 (阈值 pIC₅₀≥6.0) | 0.7234                            |      | ✓       |
| Precision         | 0.7391                            |      | ✓       |
| Recall            | 0.7083                            |      | ✓       |
| AUPRC             | 0.8190                            |      | ✓       |



## 研究点四



## 置信度加权的中药多靶点结合覆盖评估

依托 TCMSP 数据库建立天然产物成分库：构建涵盖丹参、甘草、柴胡、五味子、灵芝、黄连、苦参、水飞蓟、青蒿、雷公藤等10种保肝中药的活性成分库，着重引入萜类、木脂素、生物碱等新颖骨架，避免黄酮类、酚酸类等常见 PAINS。

ADMET 过滤  
贝叶斯 GNN  
批量推理

"域内高置信"  
域内低置信"  
域外预警"三级标注

拟计算 CW-BCS 评分

提取多靶点预测的最优加权得分，置信度权重设定为  $w = 1/(1+\sigma_i)$  维持数值稳定

将 FXR、THR- $\beta$  与 ACC 的三靶点得分方向统一后取几何均值，并引入结构冗余惩罚项

明确排除以下化合物类别：  
- 经典黄酮类：槲皮素、木犀草素、芹菜素、山奈酚、橙皮素、黄芩苷  
- 多酚酸类：咖啡酸、绿原酸、香草酸、鞣花酸、没食子酸、阿魏酸  
- 简单代谢物：胆碱、腺嘌呤、葡萄糖、棕榈酸  
- 泛活性骨架：姜黄素、白藜芦醇、EGCG

ADMET 过滤标准 (Lipinski 扩展规则)：

- 分子量： $150 < MW < 500$  Da
- 亲脂性： $\text{LogP} < 5.5$
- 氢键供体： $\text{HBD} \leq 5$
- 氢键受体： $\text{HBA} \leq 10$

初始候选数：27个 → ADMET 过滤后：26个 (全部通过)

上述分子在多种无关靶标中反复出现阳性结果，是 QSAR 模型的主要偏差来源，且临床转化成功率极低


取 CW-BCS 排名靠前中药的代表性成分，开展多靶点交叉分子对接，利用 PyMOL 解析关键氢键与残基相互作用网络，完成机理层面的交叉佐证

说明：  
CW-BCS 衡量的是多靶点结合覆盖能力，不等同于药理学意义上的协同效应；药理方向的判断由后续分子对接与文献佐证共同支撑

## 分子对接

| 参数             | 值                                               |
|----------------|-------------------------------------------------|
| 软件             | AutoDock Vina 1.2.3                             |
| FXR 结构         | PDB 3DCT (人源, Helix12激活构象, 正确大口袋)               |
| THR-β 结构       | PDB 1Q4X (人源, T3配体共结晶)                          |
| ACC 结构         | PDB 4WZB (人源ACC1 CT结构域)                         |
| 对接盒中心          | 原配体质心 (3DCT: 基于最大配体HETATM确定)                    |
| 对接盒尺寸          | 22 × 22 × 22 Å                                  |
| Exhaustiveness | 16                                              |
| 输出模式数          | 5                                               |
| 配体准备           | RDKit 3D构象生成 (ETKDGv3) + MMFF力场优化 + Meeko PDBQT |
| 受体准备           | Meeko mk_prepare_receptor (去水/非必要HETATM)        |

## Pymol 动画模拟分子对接



取 CW-BCS 排名靠前中药的代表性成分，开展多靶点交叉分子对接，利用 PyMOL 解析关键氢键与残基相互作用网络，完成机理层面的交叉佐证



文献调研；GEO 转录组 DEGs 分析确认靶点差异表达；ChEMBL 数据获取与标准化清洗，设计加权损失函数；RDKit 提取 2D 描述符，完成前置 PCA/Leverage 适用域过滤

分子图特征工程；搭建贝叶斯 GNN（MC Dropout，T=50）；可靠性图与 ECE 校准验证；GNNExplainer 可解释性分析；三层评价；与 RF/XGBoost 基线对比

TCMSP 中药成分库构建；ADMET 过滤；贝叶斯 GNN 批量推理（FXR 主靶点）；AutoDock Vina THR-β/ACC 代理评分；适用域三级标注；CW-BCS 评分计算与中药排名

代表性成分 AutoDock Vina 多靶点对接（含阳性对照）；PyMOL 关键氢键/残基可视化；中药溯源与功效对应；论文撰写。

结题材料整理；答辩准备；经费报销

## 预期研究成果

01. 建立一套带不确定性量化的 GNN 天然产物虚拟筛选方法学框架，形成开源代码与说明文档。

02. 构建经校准验证的 FXR-pIC50 贝叶斯 GNN 模型，目标达到独立测试集  $R^2$  不低于 0.60、均方根误差不高于 0.80、ECE 不高于 0.15，形成可复用的预测工具。



03. 提出并验证置信度加权结合覆盖评分 (CW-BCS)，输出中药-代表成分-靶点-置信度四维结果表，筛选 CW-BCS 排名前 5 的保肝中药。

04. 提交大创结题报告，力争形成 1 篇学术论文（普通期刊或学术会议）或阶段性研究成果。





## 主干A：贝叶斯GNN模型构建——锻造一把“可靠的智能武器”

### 01. 病理学靶点确证 (GEO数据库)

从基因组学层面系统挖掘与分析，确证FXR等关键靶点在疾病机制中的核心调控作用，为模型构建锚定精准的生物学基础

### 02. 高质量训练数据集构建 (ChEMBL数据库)

深度挖掘并标准化清洗569条FXR活性数据，严格执行PAINS过滤以去除干扰化合物，并科学划定模型适用域，保障数据质量。

### 03. 贝叶斯GNN模型搭建 (PyTorchGeometric)

基于PyTorch Geometric框架搭建轻量化图卷积网络，引入MC Dropout机制，使模型具备捕捉预测不确定性的能力。

### 04. 多维度模型验证与解释

综合运用可靠性图、期望校准误差(ECE)指标量化模型置信度，并结合GNNExplainer工具解析模型决策逻辑，确保预测结果可解释、可信赖。



## 主干B：中药筛选与评估——实战应用“智能武器”

### ▶▶▶ 01. 中药成分库构建与初筛 (TCMSP数据库)

依托TCMSP数据库建立天然产物成分库，通过ADMET（吸收、分布、代谢、排泄、毒性）成药性过滤规则，系统性淘汰溶解度差、毒性高、生物利用度低的分子，为后续筛选筑牢数据基础。

### ▶▶▶ 02. 基于不确定性的二级筛选 (贝叶斯GNN模型)

将初筛分子输入预训练的贝叶斯GNN模型，量化预测的不确定性，将结果分为“域内高置信”、“域内低置信”和“域外预警”三类，优先锁定预测可靠且活性达标的候选分子，降低实验风险。

### ▶▶▶ 03. 多靶点综合评估 (独创CW-BCS评分体系)

应用CW-BCS（协同权重-结合评分）公式，综合考量分子对FXR、THR- $\beta$ 和ACC三个关键靶点的结合亲和力与协同作用潜力，实现从“单靶点活性”到“多靶点协同”的深度评估。

### ▶▶▶ 04. 分子作用机理的终极佐证 (对接与可视化)

利用AutoDock Vina进行分子对接交叉核验，结合PyMOL完成结合模式的三维可视化分析，直观展示候选分子与靶点的结合位点、氢键作用及构象变化，形成完整的筛选与验证逻辑闭环。



## 可行性分析-预实验



从 ChEMBL 数据库 (目标 ID: ChEMBL2047, FXR/胆汁酸受体) 下载人源体外  $IC_{50}$  活性数据:

**原始记录:** 3,247条

**标准化处理:** 去重、去除混合物、统一单位至  $\mu M$

**PAINS 过滤:** 使用 RDKit FilterCatalog (PAINS\_A + PAINS\_B + PAINS\_C) 去除泛活性干扰化合物  $pIC_{50}$

**转换:**  $pIC_{50} = -\log_{10} (IC_{50} / 10^6)$

**适用域过滤:** PCA + 杠杆分析 ( $h > 3 \times hh$ ), 去除高杠杆离群点

**最终训练集:** 1,847个化合物,  $pIC_{50}$  范围 4.2-9.6

### 总结

本研究完成了数据集的预处理与筛选全套预实验工作, 为后续模型构建与机制研究奠定了基础。本次实验初始原始化合物数据共计 3247条, 为保障数据的规范性、有效性与可靠性, 开展了多维度数据清洗与优化处理。






### 优化

GNN  
模型训练  
数据集深度  
优化

化合物  
作用动力学  
机制可行性  
验证

化合物  
毒性风险  
评估研究

# 可行性分析—数据与算法



## 01. 高质量数据集储备

依托ChEMBL 数据库，获取海量针对FXR等关键靶点的实验数据，数据量级与标注质量完全满足模型训练与验证的核心需求。

## 02. 数据清洗与特征增强

建立标准化数据清洗流程过滤噪声；引入ChemBERTa 预训练分子特征，有效提升小样本场景下模型的泛化能力与预测稳健性。

## 03.成熟算法框架与算力保障

### 算法实现

基于PyTorch框架，兼容GNN与MC Dropout等前沿算法，团队具备复现与优化的工程能力。

### 算力资源

项目所需计算任务均可在现有GPU集群中完成，无需额外超算支持，成本可控且部署高效。



## 可行性分析—风险控制与团队配置

### 01. 过拟合风险管控

采用轻量化GCN/GIN网络架构，降低模型复杂度；并引入分层交叉验证及加权损失函数策略，有效抑制模型对训练数据的过度拟合，提升泛化能力。

### 02. 数据匮乏风险应对

针对部分靶点实验数据稀缺的痛点，采用分子对接结合能作为代理评分，有效扩充特征空间，规避了小样本场景下建模崩溃的风险，保障输入数据可靠性。

### 多学科交叉

汇聚药学、生物医学工程、中药学等专业人才，构建复合型研究梯队。

### 职责清晰分工

药理机制把控、算法代码实现、中医药理论解读，各环节分工明确高效协同。

### 资深学术指导

指导教师深耕数理统计与生物信息学领域，提供全程科研方法论与技术把关。



## 创新点一



## 引入预测不确定性量化 (UQ)

## 打破局限:

彻底摒弃传统虚拟筛选“仅呈现预测数值，忽视结果可信度”的固有缺陷，建立起以不确定性分析为核心的新型筛选范式，让模型输出更具参考价值。

## 核心价值:

基于MC Dropout输出预测方差并完成置信度校准，赋予筛选结果严谨的统计学分层依据，能精准剔除低可信度候选物，显著降低后续无意义的实验验证成本与时间损耗。



## 创新点二



## 置信度加权多靶点结合覆盖评分 (CW-BCS)

## 科学评估:

将模型的不确定性输出转化为关键权重因子，有机融合GNN预测值与传统物理对接评分，构建多维度评估体系，实现对中药复杂成分群多靶点协同结合潜力的客观、量化与科学化评判。

## 填补空白:

有效衔接了基于数据驱动的现代计算药物发现 (CADD) 技术与注重整体、系统的中医药学理论体系，填补了二者之间的方法论鸿沟，为中药现代化研究提供了较新的技术路径。



## 创新点三



## 不确定性驱动的双层适用性域预警机制

## 阶梯式预警体系：

结合线性与非线性分析，构建“域外直接剔除”与“域内方差分级”的双重筛选阶梯，严控预测风险。

## 填补衔接鸿沟：

有效弥合传统适用性域分析与深度学习“黑盒”模型间的理论与应用断层，提升模型鲁棒性。

## 创新点四



## GNNExplainer增强预测可解释性

## 解析决策逻辑：

利用GNNExplainer提取关键原子子图，定位模型关注的药效团结构特征，揭开“黑盒”决策的内部机制。

## 提升科学可信度：

让计算结论与中药传统功效认知相互印证，增强了模型预测结果在学术与应用层面的说服力。



## 创新点五



## 聚焦民族药与老药新用的计算视角

锁定优质筛选对象：

选取具备长期临床安全应用基础的民族药及经典保肝中药，规避新药研发早期的安全性风险。

挖掘潜在应用价值：

为抗MASH天然药物研究提供兼具安全性背书与计算可信度的候选资源，加速成果转化进程。



# 经费预算

| 序号 | 支出项目                              | 金额（元） |
|----|-----------------------------------|-------|
| 1  | 云计算资源费（租用 GPU 算力服务器进行模型训练和分子对接计算） | 1000  |
| 2  | 文献数据与资料费用（专业数据库查阅以及算法参考文献）        | 500   |
| 3  | 版面费（用于预期学术产出的学术论文在相关学术期刊发表）       | 2000  |
| 4  | 耗材费（用于阶段性报告打印装订与重要数据的移动存储设备）      | 500   |
| 总计 |                                   | 4000  |



# 谢谢观看

基于贝叶斯图神经网络的  
抗MASH天然药物筛选项目

