

沈阳药科大学
大学生创新创业训练计划项目
申 报 书

项目名称： 基于贝叶斯图神经网络的抗 MASH 天然药物筛选

项目类别： 创新训练项目☒ 创业训练项目☐ 创业实践项目☐

项目负责人： _____

学院、年级、专业： _____

项目组成员： _____

指导教师： _____

立项时间： 2026 年 6 月

沈阳药科大学创新创业学院 制

二〇二六年六月

填 写 说 明

1. 申请书的各项内容要实事求是，真实可靠。文字表达明确严谨。空缺项要填“无”。
2. 表中空格不够时，可另附页，但页码要清楚。
3. 项目申报书限用 A4 纸张填报双面打印并装订成册。
4. 项目申请人必须为全日制在校本科学生，硕士研究生和博士研究生不能作为项目负责人或者项目组成员参加大学生创新创业训练项目。
5. 各学院要组织专家对申报书的内容进行严格审核，并对所填内容的真实性负责。

一、基本情况简表

项目名称	基于贝叶斯图神经网络的抗 MASH 天然药物筛选
项目来源	1. 导师课题 2. 自主选题 3. 竞赛项目 4. 其它来源____ 2 ____
项目所属学科	药学
项目实施时间	起始时间： 2026 年 6 月 完成时间： 2027 年 6 月

二、项目简介（200 字以内）

本项目以抗 MASH 核心靶点 FXR 为锚点，构建基于 MC Dropout 的贝叶斯图神经网络，使模型在预测 pIC_{50} 的同时量化预测不确定性，并借助可靠性图进行校准验证。在此基础上，拟提出置信度加权的多靶点结合覆盖评分（CW-BCS），以置信度对各成分活性贡献进行赋权，筛选兼具高预测活性与高可靠性的天然产物，为抗 MASH 药物发现提供严谨的方法学框架。

三、项目背景及研究意义（同类研究工作国内外研究现状与存在的问题等）

1. MASH 研究现状与药物研发需求

代谢相关脂肪性肝炎（MASH）由脂质代谢紊乱、慢性炎症及肝纤维化共同参与，已成为全球慢性肝病的重要类型。法尼醇 X 受体（FXR）在脂质稳态及炎症调控中发挥关键作用，是公认的核心靶点。尽管 2024 年 FDA 加速批准了甲状腺激素受体 beta（THR- β ）激动剂 resmetirom，但其伴有肝毒性风险；而 FXR 激动剂亦存在瘙痒、脂代谢异常等副作用。这提示单靶点强激动策略存在显著局限。相比之下，天然小分子多靶点弱协同调控的特性，为 MASH 治疗提供了极具潜力的补充方向。民族药与经典保肝中药因其长期临床安全基础，构成了极佳的候选资源池。

2. 现有虚拟筛选方法的核心方法学瓶颈

目前计算机辅助药物设计（CADD）在天然产物筛选流程中，存在一个亟待解决的方法学瓶颈：主流 QSAR/GNN 模型均仅输出单一点估计值，却不提供该预测值的统计置信度。这一缺陷在天然产物筛选中尤为致命。其一，公开数据库训练集以合成小分子为主，天然产物的高结构多样性常导致模型陷入过度外推（Over-extrapolation）困境，点估计值无法揭示此潜在风险。其二，缺乏置信度评估导致筛选结果中高置信的真实活性分子与模型外推产生的假阳性分子严重混杂，极大增加了下游实验验证的沉没成本。其三，传统中药信息学多对单体成分进行等权评估，忽视了不同成分预测置信度的客观差异，导致整体协同评估结论的可靠性难以保证。

3. 本项目的研究意义与方法学贡献

本项目尝试将预测不确定性量化（Uncertainty Quantification, UQ）系统性引入天然产物虚拟筛选全流程。通过构建贝叶斯 GNN，使模型在输出 pIC₅₀ 预测均值的同时输出预测方差，并辅以预期校准误差（ECE）验证，确保不确定性估计真实可信。同时，拟创新性地提出置信度加权的中药多靶点结合覆盖评分（CW-BCS），在 FXR/THR- β /ACC 三靶点维度客观评估中药的整体覆盖潜力。本研究不仅为抗 MASH 天然药物筛选提供切实的数据支撑，更有望填补 CADD 与中医药计算体系之间的方法学空白。

四、研究内容和拟解决的关键问题（包括研究内容、研究目标、研究方法、实验方案、技术路线、可行性分析以及拟解决的关键问题等）

（一）研究内容

1. MASH 核心靶点的转录组学确证

从 GEO 数据库获取 MASH 患者肝组织转录组数据集，利用 R 语言 (DESeq2/limma) 开展差异表达基因 (DEGs) 分析及通路富集，在组学层面确证 FXR、THR- β 、ACC 等靶点在患者样本中的显著差异表达。此步骤旨在为后续“以 FXR 为建模主锚点、以 THR- β / ACC 为空间对接验证靶点”的筛选策略提供坚实的病理学依据。正式执行前需核对数据集的样本类型、物种、疾病分组及测序平台信息。

2. 高质量活性数据集构建与前置适用域过滤

利用 Python 从 ChEMBL 数据库获取 FXR 纯化蛋白体外实验数据，经项目组前期预实验挖掘与整理，已确证可获得高质量有效活性数据约 569 条。预处理流程包括：SMILES 标准化、PAINS 化合物过滤，并将 IC_{50} 转化为 pIC_{50} 。针对数据的长尾分布特性，引入加权损失函数 (Weighted Loss) 以缓解模型对高活性稀有样本的忽视。在构建分子图前，利用 RDKit 提取 2D 物理化学描述符，基于 PCA/Leverage 方法构建适用域 (AD) 边界，剔除超域离群样本净化输入源，并为后续天然产物的域外预警确立参照基准。

3. 带不确定性量化的贝叶斯图神经网络构建

将清洗后的分子表示为异构图结构 (纳入杂化状态、氢键供受体、芳香环等特征)，基于 PyTorch Geometric 构建轻量化图卷积网络。与传统模型不同，本项目在推理阶段保持 MC Dropout 层激活，重复前向传播 T 次 ($T=50$)，生成 pIC_{50} 的预测分布，以均值 μ 作为活性估计，方差 σ^2 作为不确定性度量。模型输出升级为 $\mu \pm \sigma$ 形式——高置信样本方差 σ 极小，低置信样本方差 σ 显著放大，实现筛选结果的可信度分层。

此外，引入可靠性图 (Reliability Diagram) 与 ECE 指标进行校准验证，确保 σ 真实反映预测误差；并通过 GNNExplainer 提取关键原子子图，解析模型关注的药效团，为中药功效提供可视化解读支撑。模型性能将从回归 (R^2 、RMSE)、分类 (F1-score、AUPRC) 及不确定性校准三个维度与基线模型 (RF/XGBoost) 进行对比评估。

4. 置信度加权的中药多靶点结合覆盖评估

依托 TCMSp 数据库建立天然产物成分库，依次开展 ADMET 过滤与贝叶斯 GNN 批量推理。依据不确定性输出，将分子划分为“域内高置信”“域内低置信”及“域外预警”三级标注。

在此基础上，拟计算 CW-BCS 评分：针对各成分，提取多靶点预测的最优加权得分，置

信度权重设定为 $w = 1/(1 + \sigma_i)$ 以维持数值稳定；将 FXR (GNN 推理得分)、THR- β 与 ACC (以 AutoDock Vina 结合能 ΔG 为代理评分, 规避小样本强行建模风险) 的三靶点得分方向统一后取几何均值, 并引入结构冗余惩罚项。需要说明的是, CW-BCS 衡量的是多靶点结合覆盖能力, 不等同于药理学意义上的协同效应; 药理方向的判断由后续分子对接与文献佐证共同支撑。最终, 取 CW-BCS 排名靠前中药的代表性成分, 开展多靶点交叉分子对接, 利用 PyMOL 解析关键氢键与残基相互作用网络, 完成机理层面的交叉佐证。

(二) 研究目标

1. 构建带不确定性量化的 GNN 天然产物虚拟筛选方法学框架, 形成开源预测代码流。
2. 建立经校准验证的 FXR-pIC₅₀ 贝叶斯 GNN 模型, 预期独立测试集 R^2 不低于 0.60、RMSE 不高于 0.80、ECE 不高于 0.15。
3. 提出并验证置信度加权结合覆盖评分 (CW-BCS), 筛选排名前 5 的抗 MASH 保肝中药及其代表性活性成分。
4. 提交大创结题报告, 力争形成 1 篇学术论文或阶段性研究成果。

(三) 研究方法与技术路线

技术路线以两条主干并行推进, 详见下图。主干 A 为贝叶斯 GNN 建模主线 (交付底线): 从 GEO 转录组差异基因分析出发, 经 ChEMBL 数据获取、标准化清洗与加权损失设计, 完成前置适用域过滤后构建分子图, 训练带 MC Dropout 的贝叶斯 GNN 并输出均值与方差, 经可靠性图与 ECE 校准验证、GNNExplainer 可解释性分析和三层指标评价, 与基线模型对比完成主线交付。主干 B 为中药结合覆盖评估 (方法学拔高出口): 基于 TCMSp 成分库完成 ADMET 过滤后, 由贝叶斯 GNN 完成 FXR 主靶点批量推理, THR- β 和 ACC 靶点采用 AutoDock Vina 对接代理评分, 经适用域三级标注后计算 CW-BCS 并完成中药排名, 最终对代表性成分开展多靶点对接佐证和 PyMOL 可视化, 汇总结果形成论文。




图1 项目技术路线图

(四) 可行性分析

1. 数据与算法

经预实验确证, ChEMBL 现有 FXR 高质量数据足以支撑轻量级模型训练。若严格清洗后数据折损, 备选方案为引入 ChemBERTa 等预训练特征表示以提升模型在小样本下的稳健性。MC Dropout 及 ECE 等统计组件在 PyTorch 框架中兼容性良好, 团队具备独立实现能力, 1000

元 GPU 算力可完全满足训练与推理需求。

2. 风险控制

采用两到三层轻量化 GCN/GIN 避免参数冗余，通过分层交叉验证及加权损失函数控制过拟合。针对 THR- β 与 ACC 数据匮乏的痛点，采用分子对接结合能作为代理评分，规避了小样本建模的崩溃风险，保障了 CW-BCS 输入源的科学性与可靠性。

3. 团队配置

团队涵盖药学、生物医学工程与中药学专业，药理机制把控、不确定性量化代码实现及中医药学解读分工明确。指导教师具备深厚的数理统计生物信息学背景，可为项目提供全程学术保障。

（五）拟解决的关键问题

- 1. 天然产物结构异质性导致的预测假阳性：**通过前置 PCA/Leverage 适用域过滤与 MC Dropout 方差输出，双重规避模型在化学空间盲区中的过度推断。
- 2. 长尾分布下的模型学习偏倚：**设计针对 pIC50 活性区间的加权损失函数，提升模型对极高活性成分的特征捕获能力。
- 3. 传统单分子评估向协同评价的过渡：**构建 CW-BCS 计算模型，量化成分群对多靶点的整体覆盖度，解决单纯罗列中药成分而缺乏科学加权依据的难题。

五、项目创新之处

1. 突破性引入预测不确定性量化 (UQ)

彻底打破了传统虚拟筛选“只见预测值，不见可信度”的方法学局限。基于 MC Dropout 架构输出预测方差并完成校准，使筛选结果具备严谨的统计学置信度分层，显著降低无意义的实验验证成本。

2. 创新性提出置信度加权多靶点结合覆盖评分 (CW-BCS)

将模型的不确定性输出转化为权重因子 $w = 1/(1 + \sigma_i)$ ，结合 GNN 预测值与物理对接代理评分，实现了对中药复杂成分群多靶点结合潜力的科学量化评估，填补了 CADD 与中医药计算体系之间的方法学空白。

3. 建立不确定性驱动的双层适用域预警机制

将 2D 描述符层的线性适用域过滤，与深度模型输出的非线性置信度方差相结合，形成“域外直接剔除”与“域内方差分级”的阶梯式预警体系，填补了传统适用域分析与深度学习黑盒之间的衔接空白。

4. GNNExplainer 增强预测可解释性

通过 GNNExplainer 提取高活性预测分子的关键原子子图及边权重，解析模型关注的药效团结构特征，使计算预测结论能够与中药传统功效的药效团理解相互对应，增强结果的科学可信度。

5. 聚焦民族药老药新用的计算视角

以已具长期临床安全应用基础的民族药及药典保肝中药为筛选对象，借助上述方法学框架评估其多靶点结合覆盖潜力，为抗 MASH 天然药物研究提供兼具安全性依据与计算可信度的候选资源。

六、项目进度安排（查阅资料、选题、自主设计项目研究方案、开题报告、实验研究、数据统计、处理与分析、研制开发、填写结题表、撰写研究论文和总结报告、参加结题答辩和成果推广等）

2026.06—2026.08: 文献调研；GEO 转录组 DEGs 分析确认靶点差异表达；ChEMBL 数据获取与标准化清洗，设计加权损失函数；RDKit 提取 2D 描述符，完成前置 PCA/Leverage 适用域过滤

2026.09—2026.11: 分子图特征工程；搭建贝叶斯 GNN (MC Dropout, T=50)；可靠性图与 ECE 校准验证；GNNExplainer 可解释性分析；三层评价；与 RF/XGBoost 基线对比

2026.12—2027.02: TCMSP 中药成分库构建；ADMET 过滤；贝叶斯 GNN 批量推理 (FXR 主靶点)；AutoDock Vina THR- β /ACC 代理评分；适用域三级标注；CW-BCS 评分计算与中药排名

2027.03—2027.05: 代表性成分 AutoDock Vina 多靶点对接 (含阳性对照)；PyMOL 关键氢键/残基可视化；中药溯源与功效对应；论文撰写。

2027.06: 结题材料整理；答辩准备；经费报销

七、预期研究成果（如项目鉴定、学术论文、申请专利、获奖、推广应用等）

1. 建立一套带不确定性量化的 GNN 天然产物虚拟筛选方法学框架，形成开源代码与说明文档。
2. 构建经校准验证的 FXR-pIC50 贝叶斯 GNN 模型，目标达到独立测试集 R^2 不低于 0.60、均方根误差不高于 0.80、ECE 不高于 0.15，形成可复用的预测工具。
3. 提出并验证置信度加权结合覆盖评分（CW-BCS），输出中药-代表成分-靶点-置信度四维结果表，筛选 CW-BCS 排名前 5 的保肝中药。
4. 提交大创结题报告，力争形成 1 篇学术论文（普通期刊或学术会议）或阶段性研究成果。

八、经费预算（如材料费、资料费、版面费、专利费、调研费等）

序号	支出项目	金额（元）
1	云计算资源费（租用 GPU 算力服务器进行模型训练和分子对接计算）	1000
2	文献数据与资料费用（专业数据库查阅以及算法参考文献）	500
3	版面费（用于预期学术产出的学术论文在相关学术期刊发表）	2000
4	耗材费（用于阶段性报告打印装订与重要数据的移动存储设备）	500
合计		4000

九、项目负责人意见

本项目直击当前天然产物虚拟筛选中点估计模型缺乏可信度评估的底层痛点，创新性地将不确定性量化（UQ）引入 GNN 筛选框架，并提出基于置信度加权的中药多靶点评分系统。项目底层逻辑严密，风险对冲方案完善，团队交叉互补优势显著，具备极强的落地可行性与科研价值。本人承诺在实施中恪守学术规范，科学统筹经费与进度，全力保障各项创新性指标的高质量交付。

项目负责人签名：

2026 年 6 月 1 日

十、指导教师推荐意见（从项目学术性、创新性、可行性、研究性、可操作性和成效性加以评价）

该项目紧扣抗 MASH 药物研发前沿，创新性引入贝叶斯图神经网络量化预测不确定性，并提出置信度加权评分（CW-BCS），突破了传统虚拟筛选的假阳性瓶颈，学术与应用价值预测明确。团队跨学科优势互补，前期预实验充分，技术路线切实可行。本人将全力指导，特此推荐立项！

签名：

2026 年 6 月 1 日

十一、学院推荐意见

学院负责人签名：

学院盖章：

年 月 日

十二、学院专家评审意见

专家组组长签名：

年 月 日

十三、学校评审意见

学校负责人签名：

学校公章：

年 月 日