

大创项目全流程综合结题分析报告

生成日期: 2026-08-24 | 分析对象: 本大创项目全生命周期所有文件 (V1, V2, V3, 圆桌审计)

〇、执行摘要 (Executive Summary)

本大创项目完整经历了从“初次探索 (V1)”到“代码与数据独立审计 (V3)”，再到“方法学推倒重构 (V2)”的真实、高质量的科研闭环。

项目最杰出的科研价值不仅在于“筛出了几个候选药物”，而在于真实地发现了AI在预测天然产物时存在的“适用域外推失效”现象，并以此为契机完成了计算管线的全面进化。

一、项目演进全景与三套具体流程 (Full Timeline & Workflows)

整个工作区的数据和报告，实际上映射了项目在不同认知阶段建立的三条独立管线：

管线一：初始履约管线 (V1 方案，文件夹：mash_research)

- 研发目的**：完成立项申报书中承诺的基于图神经网络的筛选任务。
- 疾病模块与靶点**：基于GEO(GSE135251)数据，锁定单一核受体 **FXR(NR1H4)** 为主靶点。
- 化合物库**：10味经典保肝中药，解析出 **131** 个化学成分。
- 算法模型**：贝叶斯图神经网络(BGNN)，结合异方差NLL与MC Dropout进行不确定性量化。
- 筛选机制**：首创 CW-BCS (置信度加权结合覆盖评分) 体系，进行绝对分数排名。
- 独立结论**：计算得出**黄连（及其成分小檗碱/表小檗碱）**综合排名第一。
- 局限性暴露**：在后期圆桌审议中发现，深度学习模型对天然产物出现了严重的“过拟合”与“骨架崩塌”（外推 R^2 降至-0.61），且纯计算高分子的购买可行性与真实机制存疑。

管线二：第三方审计与湿实验落地管线 (V1+ 方案, 文件夹:

verify_repro, roundtable)

- **研发目的**: 为确保学术诚信, 对V1进行代码重写复算; 同时为了指导真实的1500元湿实验采购, 对候选物进行严苛的落地清洗。
- **100% 独立复现**: 通过全新的Python与MATLAB脚本, 独立重做了V1的T检验、ChEMBL过滤、杠杆值(Leverage)计算等, **证明了V1所有计算结果与底层数据100%真实吻合, 无任何数据造假**。
- **严苛的人工修正**: 剔除了无商品化供应的分子(如某真菌提取物)、剔除了含肝毒性(PA)的千里光, 引入“临床/机制文献直证”双链逻辑, 形成统一综合评分“V5 Unified Score”。
- **独立结论**: 在排除了黄连等部分存在疑虑的纯计算产物后, 最终锁定 **樟芝群 (Antcin K等)** 与 **积雪草 (asiatic acid)** 为可以直接投入 HepG2脂变湿实验的首选安全对象。

管线三：完全独立重构的新方法管线 (V2 方案, 文件夹:

mash_v2_new)

- **研发目的**: 吸收前期所有教训, 摒弃容易过拟合的DL模型与单一靶点, 做一次真正符合顶级学术逻辑的推倒重来 (即您最后看到的PDF可视化报告)。
- **靶点组合升级**: 转向国际最新前沿, 采用 **THR β (激动) + FASN(抑制) + SCD1(抑制)** 协同调控轴 (由双队列GSE48452+GSE63067独立跨界验证)。
- **算法回归鲁棒性**: 弃用深层网络, 改用 **XGBoost/Random Forest (随机森林)** 集成模型 + Morgan指纹。
- **化合物库换血**: 全新引入另外10味文献驱动的药材 (葛根、山楂等), 提取出 **54** 个完全不同的化合物。
- **评估与排序体系**: 引入 Butina 聚类, 强行考察“化学骨架外推能力”; 采用运筹学成熟的 **TOPSIS 多准则决策系统** 进行全面排序。
- **独立结论**: 筛选出 **葛根 (3'-甲氧基大豆黄素)**、**山楂**、**茵陈** 为最高优候选。
- **核心科学贡献**: 报告以极为诚实的态度证明, 54个天然分子全部在已知训练集的化学空间之外(最大相似度仅0.29), 因此所有预测结果被主动降级为 **"假设生成级 (Hypothesis-generating)"**, 拒绝夸大宣传。

(注: 期间曾短暂探索过生物药如FGF21和海洋未知真菌冷门分子, 但均因“缺乏冷门生态位”和“本科生无法购买/合成”而被务实地否决, 此举体现了团队绝

佳的商业与现实洞察力。)

二、三套方法结果为何不同？(核心区别对照)

为什么折腾了三遍，得出的药物都不一样？这正是AI辅助计算筛选的核心特征——**输入不同的生物学假设和搜索空间边界，必然得出不同的结果。**

对比维度	V1 (初始履约路线)	V1+ (圆桌审计实验落地)	V2 (全新重构路线 / PDF)
生物学靶点 (锁)	FXR 单一核受体	FXR 单一核受体	THRβ + FASN + SCD1 协同多靶点
中药筛选库 (钥匙)	第一批10味经典药(131分子)	第一批中排查出的“可真实购买”分子	第二批全新10味药(54分子, 0重叠)
筛选与评估算法	贝叶斯 GNN (深度学习)预测	GNN计算 + 人工临床/采购过滤	XGB/RF树模型集成 + TOPSIS排序
最终推举结果	黄连 (小檗碱)	樟芝、积雪草	葛根、山楂、茵陈

结论：这三个结果**互相绝不矛盾**。黄连是FXR路线的最佳纯计算结果；樟芝是该路线下最稳妥的可进行细胞实验的对象；而葛根/山楂则是基于最新的多靶点协同路线下的探索最优解。

三、结题报告的终极撰写建议 (How to Close the Project)

基于上述全景分析，如果想要顺利且完美地结题，建议您按以下“三步走”结构组织您的结题材料，这将使该项目的科研深度超越绝大多数普通的大创水准：

1. **【主要工作交付】第一章：计算与模型构建 (对应 V1)**
向评委汇报你们如何搭建了复杂的BGNN模型，筛选了131个中药成分。**交付黄连/苦参排名的原表**。这一章的目的是证明：我们代码跑通了，申报书任务圆满完成了。

2. **【实验落地设计】第二章：模型审计与湿实验规划 (对应 V1+)**

向评委汇报你们为了学术严谨，不仅自己对代码做了100%第三方复现，还对AI算出来的结果进行了真实的采购与毒理排查。**交付以樟芝/积雪草为主的、预算在1500元以内的HepG2脂变模型实验计划**。这一章的目的是展示你们具备将“干实验”落地为“湿实验”的顶级转化能力。

3. **【亮点与升华】第三章：方法学的反思与重构 (对应 V2)**

在最后把那份 **测出葛根/山楂的PDF可视化报告** 亮出来，作为项目的**“超预期延伸成果 (Bonus)”**。

答辩升华话术推荐：“通过一年的探索，我们深刻认识到了当前AI预测天然产物的痛点——严重的适用域外推失效。因此在结题前，我们自发推倒重来，构建了一套靶点更新、不确定性披露更严苛的V2多靶点协同管线。尽管我们现在只能给出‘假设生成级’的结论，但这套诚实的重构体系为我们后续的科研探索建立了真正的标杆。”